

Penerapan Teknik *Machine Learning* untuk Menghasilkan Jalur Diagnostik Laboratorium: Studi Kasus Deteksi Hepatitis C.

Mata Kuliah: Pembelajaran Mesin.

Dosen Pengampu: Junta Zeniarja, M.Kom.

Tipe Tugas: Ujian Akhir Semester (UAS)



Ditulis oleh:

Nama : Arsah Cipta Adi Stiyanto

NIM : A11.2024.15701

**PROGRAM STUDI SARJANA TEKNIK INFORMATIKA FAKULTAS
ILMU KOMPUTER UNIVERSITAS DIAN NUSWANTORO
SEMARANG 2026**

1. Identifikasi dan Penjelasan Masalah: Prediksi Pasien Terjangkit Hepatitis

Hepatitis C merupakan salah satu penyakit infeksi menular yang menyerang organ hati dan dapat memicu kondisi kronis berbahaya seperti **Fibrosis** (pembentukan jaringan parut) hingga **Cirrhosis** (kerusakan hati stadium akhir). Masalah klinis utama yang dihadapi oleh dunia medis saat ini adalah lambatnya deteksi dini. Banyak pasien tidak menunjukkan gejala spesifik hingga kerusakan hati telah mencapai stadium lanjut.

Melalui pendekatan *Machine Learning*, masalah ini dapat dimitigasi dengan memanfaatkan data uji laboratorium klinis (*blood test parameters*). Parameter biokimia seperti kadar enzim hati (ALT, AST, ALP, GGT) dan protein (ALB, PROT) membawa pola atau sinyal tersembunyi mengenai kondisi kesehatan hati pasien.

Dengan membangun model prediktif, kita dapat menyelesaikan masalah penapisan (*screening*) medis, yaitu secara cepat memisahkan individu yang sehat (donor darah normal) dari pasien yang berisiko terjangkit Hepatitis atau yang sedang bertransisi menuju penyakit hati kronis lainnya. Deteksi dini ini memungkinkan intervensi medis yang cepat, efisien dari segi biaya, serta mampu menyelamatkan nyawa sebelum pasien jatuh ke kondisi sirosis.

2. Penentuan Target Klasifikasi dan Alasan Ilmiah Pemilihan Metode Target Klasifikasi

Berdasarkan audit pada dataset yang digunakan (HepatitisCdata.csv), target klasifikasi yang ditentukan adalah variabel **Category**. Variabel ini memiliki karakteristik *multi-class* yang terdiri dari 5 label diskrit yang telah diverifikasi oleh pakar medis, yaitu:

- 0=Blood Donor (Individu sehat / Donor Darah)
- 0s=suspect Blood Donor (Dugaan/Suspek)
- 1=Hepatitis (Terinfeksi Hepatitis)
- 2=Fibrosis (Mengalami Fibrosis)
- 3=Cirrhosis (Mengalami Sirosis)

Alasan Ilmiah Mengapa Kasus Ini Termasuk *Supervised Classification*

Pemilihan metode *Supervised Classification* (Klasifikasi Terbimbing) didasarkan pada landasan teoritis dan karakteristik data berikut:

- **Mengapa *Supervised*, Bukan *Clustering* (Unsupervised)?** Dalam skenario *Unsupervised Learning* seperti *clustering*, algoritma bekerja tanpa mengetahui label target sama sekali; ia hanya mengelompokkan data berdasarkan kemiripan jarak antarfitur secara buta. Sementara itu, pada kasus ini, kita memiliki **ground-truth** atau label referensi yang jelas (Category) hasil diagnosis para ahli biokimia. Pendekatan *Supervised Learning* dipilih karena tujuan kita adalah **melatih model untuk**

memetakan fitur biokimia darah ke label diagnosis yang sudah pasti, bukan mencari kelompok baru yang tidak diketahui maknanya.

- **Mengapa Klasifikasi, Bukan Regresi?** Secara fundamental, perbedaan klasifikasi dan regresi terletak pada skala variabel targetnya. Regresi digunakan jika variabel target bersifat kontinu/numerik tak terbatas (misalnya memprediksi nilai tekanan darah atau angka harapan hidup pasien). Pada kasus hepatitis ini, output yang diinginkan adalah **keputusan klinis berupa kategori atau kelas diskrit (nominal/ordinal)**. Pasien harus ditempatkan ke dalam salah satu dari kompartemen diagnosis yang sudah ditentukan (apakah dia sehat, menderita hepatitis, atau sirosis). Oleh karena itu, pendekatan regresi secara ilmiah tidak valid untuk kasus ini, dan *classification* adalah satu-satunya metode yang tepat.

3. Tabel State-of-the-Art Mini untuk Desain Optimasi Project

Tahun	2018
Penulis	Georg Hoffmann, Andreas Bietenbeck, Ralf Lichtinghagen, Frank Klawonn
Judul Singkat	Using machine learning techniques to generate laboratory diagnostic pathways—a case study
Jurnal	Journal of Laboratory and Precision Medicine (JLPM)
DOI	10.21037/jlpm.2018.06.01
Kontribusi untuk Project	Kontribusi: Memasukkan otomatisasi data uji laboratorium klinis ke dalam jalur diagnostik (diagnostic pathways) medis guna memisahkan donor sehat, infeksi Hepatitis, Fibrosis, hingga stadium akhir Sirosis. Hasil Performa: Model rpart standar mencapai akurasi keseluruhan sebesar 75.3%, jauh di atas tebakan medis acak (naive guess basis kelas mayoritas sebesar 42.5%). Penambahan parameter ELF menaikkan akurasi hingga 79.4%.

4. Metode Optimasi dan Validasi yang Akan Diuji

Berdasarkan analisis karakteristik dataset (adanya *missing values*, ketidakseimbangan kelas yang ekstrem, dan fitur berupa enzim/protein klinis) serta metode pohon keputusan (rpart, ctree) pada paper, berikut adalah 5 metode optimasi dan validasi yang diusulkan:

a. *Hyperparameter Tuning* (Optimasi Struktur Pohon)

- **Implementasi:** Mengoptimalkan parameter struktural pada model pohon keputusan seperti *cp* (*complexity parameter* untuk pruning pada rpart), *minsplit* (jumlah minimum sampel untuk pemisahan node), dan *maxdepth* (kedalaman maksimum pohon).

- **Tujuan:** Menghindari *overfitting* agar aturan (*if-then-else*) yang dihasilkan tidak terlalu spesifik pada data latih, sehingga tetap relevan dan memiliki *clinical plausibility* (masuk akal secara medis) saat diuji pada data baru.

b. Cross-Validation (Leave-One-Out & Stratified K-Fold)

- **Implementasi:** Mengikuti rujukan paper yang menggunakan metode *Leave-One-Out Cross-Validation* (LOOCV) atau menerapkan *Stratified K-Fold Cross-Validation* (misalnya 5-Fold atau 10-Fold).
- **Tujuan:** Mengingat jumlah sampel pasien penyakit hati dalam dataset ini relatif kecil dibandingkan populasi donor sehat, teknik *stratified* memastikan setiap lipatan (*fold*) memiliki proporsi kelas stadium fibrosis (Hepatitis, Fibrosis, Cirrhosis) yang seimbang untuk menjamin validitas metrik evaluasi.

c. Feature Selection (Seleksi Parameter Laboratorium Kritis)

- **Implementasi:** Menggunakan metode berbasis statistik seperti *Analysis of Variance* (ANOVA) atau *Mutual Information* untuk menilai signifikansi 10 fitur klinis (ALB, ALP, ALT, AST, BIL, CHE, CHOL, CREA, GGT, PROT) terhadap penentuan stadium penyakit.
- **Tujuan:** Mengidentifikasi kombinasi enzim hati yang paling diskriminatif (misalnya rasio AST/ALT atau kadar Bilirubin) untuk memangkas fitur yang redundan, menyederhanakan *diagnostic pathways*, dan menurunkan biaya skrining laboratorium di dunia nyata.

d. Imbalance Handling (Penanganan Kelas Minoritas Pasien)

- **Implementasi:** Dataset ini didominasi oleh kelas "0=Blood Donor" (donor sehat). Oleh karena itu, perlu diuji metode *Synthetic Minority Over-sampling Technique* (SMOTE), *Random Under-Sampling* (RUS), atau penyesuaian bobot kelas (*Class Weighting*) pada algoritme.
- **Tujuan:** Mencegah model mengalami bias yang cenderung memprediksi semua pasien sebagai "Donor Sehat" dan meningkatkan sensitivitas (*recall*) model dalam mendeteksi kelas minoritas yang kritis seperti stadium "2=Fibrosis" dan "3=Cirrhosis".

e. Explainability & Post-Hoc Pruning (Diagnostic Pathways)

- **Implementasi:** Mengekstraksi aturan keputusan (*rules extraction*) dari pohon keputusan menjadi format teks *if-then-else* yang bersih dan melakukan visualisasi jalur diagnostik.
- **Tujuan:** Menyediakan model yang transparan (*white-box*) agar dokter dan tenaga medis dapat menelusuri bagaimana kadar laboratorium tertentu (misalnya jika $AST > 50$ dan $CHE < 6$) mengarah pada penentuan stadium fibrosis, memenuhi aspek akuntabilitas dalam kecerdasan buatan medis.

5. Batasan Etika, Privasi, dan Tata Kelola Data

Dalam penerapan rekayasa teknologi kesehatan berbasis data pasien Hepatitis C, batasan etika dan tata kelola berikut wajib dipatuhi:

a. Anonimisasi dan De-identifikasi Tingkat Lanjut

- **Penerapan:** Data dalam HepatitisCdata.csv sudah tidak memuat nama, nomor rekam medis (MRN), atau kontak pasien. Namun, untuk menjaga privasi, nomor indeks pasien harus diacak ulang (*hashing*). Atribut demografis seperti Age (Usia) dapat dikelompokkan ke dalam rentang usia tertentu (misal: 30–39, 40–49) jika analisis spesifik per tahun usia tidak memengaruhi performa model secara signifikan.

b. Kepatuhan Regulasi Data Kesehatan (Governance)

- **Penerapan:** Seluruh proses pengelolaan dan penyimpanan data harus merujuk pada standar global seperti HIPAA (*Health Insurance Portability and Accountability Act*) atau regulasi lokal terkait perlindungan data pribadi (UU PDP). Data klinis bersifat sensitif dan tidak boleh dipindahkan atau diintegrasikan ke platform publik tanpa enkripsi end-to-end.

c. Pembatasan Penggunaan Hasil Prediksi (Asuransi & Ketenagakerjaan)

- **Penerapan:** Hasil prediksi stadium fibrosis dari model ini ketat hanya boleh digunakan untuk kepentingan triase medis dan perencanaan terapi internal rumah sakit. Hasil prediksi **dilarang keras** dibagikan atau digunakan oleh pihak ketiga seperti perusahaan asuransi untuk menolak klaim/menaikkan premi, atau oleh perusahaan untuk melakukan diskriminasi rekrutmen terhadap pengidap Hepatitis C.

d. Larangan Penggunaan Model sebagai Keputusan Klinis Tunggal

- **Penerapan:** Model *machine learning* ini diposisikan murni sebagai *Clinical Decision Support System* (CDSS) atau sistem pendukung keputusan. Keputusan akhir diagnosis, biopsi hati, atau pemberian regimen obat antivirus wajib tetap berada di tangan dokter spesialis penyakit dalam (hepatolog) atau patolog klinis. Model berfungsi memberikan efisiensi skrining awal, bukan mengambil alih otoritas medis.