

**Laporan Penelitian Penerapan Teknik *Machine Learning* untuk
Menghasilkan Jalur Diagnostik Laboratorium: Studi Kasus
Deteksi Hepatitis C.**

Mata Kuliah: Pembelajaran Mesin.

Dosen Pengampu: Junta Zeniarja, M.Kom.

Tipe Tugas: Ujian Akhir Semester (UAS)



Ditulis oleh:

Nama : Arsah Cipta Adi Stiyanto

NIM : A11.2024.15701

**PROGRAM STUDI SARJANA TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER UNIVERSITAS DIAN
NUSWANTORO SEMARANG 2026**

DAFTAR ISI

DAFTAR ISI	2
BAB I	4
PENDAHULUAN	4
1.1. Latar Belakang	4
1.2. Tujuan Project	5
1.3. Relevansi OBE	5
BAB II	6
Studi Literatur	6
2.1 Tinjauan Paper Utama	6
2.2 Tinjauan Pustaka Terkini dan Sintesis Metode Optimasi (2024–2026)	7
BAB III	8
Dataset dan data dictionary	8
3.1 Sumber Data	8
3.2 Data Dictionary (Kamus Data)	8
3.3 Etika dan Privasi Data	10
3.4 Batasan Penggunaan Dataset	10
BAB IV	11
AUDIT DATA DAN PREPROCESSING	11
4.1 Penanganan Data Hilang (<i>Missing Value</i>)	11
4.2 Pemeriksaan Duplikat dan Penanganan <i>Outlier</i>	11
4.3 <i>Encoding</i> Variabel Kategorikal	12
4.4 Standardisasi Skala (<i>Feature Scaling</i>)	12
4.5 Penanganan Ketidakseimbangan Kelas (<i>Imbalance Data</i>)	12
4.6 Pencegahan <i>Data Leakage</i> (Kebocoran Data)	12
BAB V	13
DESAIN EKSPERIMEN	13
5.1 Pembagian Data (<i>Data Splitting</i>)	13
5.2 Skenario Model <i>Baseline</i> (Garis Dasar)	13

5.3 Hyperparameter Grid Search	13
5.4 <i>Cross-Validation</i> (Validasi Silang)	14
5.5 Metrik Evaluasi Utama.....	14
BAB VI	14
HASIL EKSPERIMEN BASELINE DAN OPTIMASI.....	14
6.1 Tabel Komparasi Kinerja (Baseline vs. Optimasi).....	15
6.2 Visualisasi Kinerja	15
6.3 Analisis Confusion Matrix	16
6.4 <i>Error Analysis</i> (Analisis Kesalahan Berbasis Klinis)	17
BAB VII.....	18
PEMBAHASAN	18
7.1 Penetapan Model Terbaik (<i>Champion Model</i>)	18
7.2 Alasan Akademik dan Teknis	18
7.3 <i>Trade-off</i> : Akurasi, Kompleksitas, dan Interpretabilitas	19
7.4 Implikasi Institusi (Aplikasi Medis dan Rumah Sakit)	19
BAB VIII	20
DESAIN APLIKASI.....	20
8.1 Arsitektur <i>Backend</i> Aplikasi.....	20
8.2 Alur Antarmuka Pengguna (UI/UX Flow).....	21
8.3 <i>Screenshot</i> (Tangkapan Layar) Aplikasi	22
8.4 Panduan Menjalankan Program (<i>Deployment Guide</i>).....	22
BAB IX	24
KESIMPULAN.....	24
9.1 Capaian <i>Outcome</i> (Relevansi OBE).....	24
9.2 Keterbatasan Sistem	24
9.3 Rekomendasi Pengembangan	25
LAMPIRAN.....	26
10.1 Kode Penting.....	26
10.2 requirements.txt	26
10.3 link repository.....	26
10.4 link presentasi dan ppt.....	26
DAFTAR PUSTAKA.....	26

BAB I

PENDAHULUAN

1.1. Latar Belakang

Penyakit Hepatitis C merupakan salah satu tantangan kesehatan global yang signifikan dan menjadi penyebab utama penyakit hati kronis, sirosis, serta karsinoma sel hati (kanker hati) di seluruh dunia. Berdasarkan data dari Organisasi Kesehatan Dunia (WHO), jutaan orang secara global terinfeksi virus Hepatitis C (HCV), di mana sebagian besar di antaranya tidak menyadari infeksi tersebut karena sifat penyakit yang asimtomatik (tanpa gejala) pada stadium awal. Kondisi klinis pasien sering kali baru memburuk secara drastis ketika kerusakan hati telah mencapai tahap lanjut seperti Fibrosis tingkat tinggi atau Sirosis.

Dalam dunia medis modern, deteksi dini dan klasifikasi stadium perkembangan penyakit hati sangat krusial untuk menentukan strategi intervensi klinis yang tepat. Jalur diagnostik konvensional umumnya mengandalkan biopsi hati, yang bersifat invasif, memiliki risiko komplikasi, serta membutuhkan biaya tinggi. Sebagai alternatif non-invasif, evaluasi parameter biokimia darah rutin—seperti enzim hati (ALT, AST, ALP, GGT), protein (Albumin, Total Protein), bilirubin, kolesterol, dan kreatinin—menjadi instrumen yang sangat berharga.

Namun, kompleksitas hubungan non-linear antar parameter laboratorium ini sering kali menyulitkan praktisi medis dalam mendiagnosis stadium penyakit secara cepat dan objektif hanya melalui analisis visual manual. Oleh karena itu, integrasi teknologi *Machine Learning* sebagai Sistem Pendukung Keputusan Klinis (*Clinical Decision Support System*) menjadi sangat relevan. Dengan memanfaatkan algoritma klasifikasi prediktif, pola-pola tersembunyi dari interaksi parameter biokimia darah dapat diekstraksi untuk memprediksi apakah seorang pasien berada pada kondisi sehat (Donor Darah), terinfeksi Hepatitis, mengalami Fibrosis, atau telah mencapai stadium Sirosis.

1.2. Tujuan Project

Eksperimen dan proyek data sains ini dirancang untuk mencapai beberapa tujuan instruksional dan teknis yang spesifik, antara lain:

1. Merancang alur pra-pemrosesan data klinis yang komprehensif, mulai dari penanganan data yang hilang (*missing values*), standardisasi skala fitur biokimia, hingga mitigasi ketidakseimbangan kelas (*data imbalance*) yang ekstrem pada dataset medis.
2. Mengembangkan dan membandingkan performa tiga arsitektur *Machine Learning* yang berbeda, yaitu *K-Nearest Neighbors* (KNN) berbasis jarak, *Naive Bayes* berbasis probabilitas, dan *Support Vector Machine* (SVM) berbasis pemisahan *hyperplane*.
3. Melakukan eksperimen *hyperparameter tuning* secara sistematis melalui metode *Grid Search Cross-Validation* untuk mengoptimalkan parameter SVM (khususnya nilai *Cost C* dan *Gamma γ* pada kernel RBF) guna menghasilkan model dengan kemampuan generalisasi tertinggi.
4. Mengintegrasikan model terbaik yang telah dilatih ke dalam antarmuka aplikasi berbasis web interaktif menggunakan *framework* Streamlit, sehingga fungsionalitas model dapat diuji dan digunakan secara langsung oleh pengguna atau tenaga medis.

1.3. Relevansi OBE

Proyek Ujian Akhir Semester (UAS) ini disusun dengan mengadopsi prinsip *Outcome-Based Education* (OBE), sebuah paradigma pendidikan yang berfokus pada capaian pembelajaran nyata yang dapat didemonstrasikan oleh mahasiswa setelah menyelesaikan masa studi. Relevansi proyek ini terhadap pemenuhan Sub-Capaian Pembelajaran Mata Kuliah (Sub-CPMK) di bidang *Machine Learning* dan *Data Science* digarispawahi oleh poin-poin berikut:

- **Sub-CPMK Audit Data & Rekayasa Fitur:** Mahasiswa dituntut memiliki kompetensi analitis untuk mengevaluasi kualitas data mentah (seperti pada notebook kode Sub-CPMK 101.1), memahami karakteristik data biokimia, serta mengambil keputusan pra-pemrosesan yang valid secara teoretis demi menghindari fenomena *data leakage*.
- **Sub-CPMK Desain Eksperimen & Evaluasi Kritis:** Melalui proyek ini, mahasiswa mendemonstrasikan kemampuan merancang metodologi eksperimen yang valid (menggunakan skema *stratified split* dan *K-Fold cross-validation*) serta mengevaluasi model menggunakan metrik akurasi yang objektif untuk data tidak seimbang, seperti *F1-Score Macro*, bukan sekadar melihat akurasi global.

- **Sub-CPMK Deployment & Problem Solving:** OBE menekankan pada penciptaan solusi nyata atas permasalahan di masyarakat atau industri. Proses penulisan skrip aplikasi web (`app_streamlit.py`) dan pengeksporan model (`best_svm_hepatitis.joblib`) membuktikan bahwa mahasiswa tidak hanya menguasai teori komputasi di lingkungan lokal (*Jupyter Notebook*), tetapi mampu menjembatani model matematis menjadi produk perangkat lunak yang fungsional dan siap pakai di lingkungan klinis.

BAB II

Studi Literatur

2.1 Tinjauan Paper Utama

Penelitian ini didasarkan pada draf metodologi klinis yang dipelopori oleh Hoffmann, G., Bietenbeck, A., Lichtinghagen, R., & Klawonn, F. (2018) dalam artikel ilmiah mereka yang berjudul “*Using machine learning techniques to generate laboratory diagnostic pathways—a case study*” yang diterbitkan pada *Journal of Laboratory and Precision Medicine*, Vol. 3, Halaman 58.

- **Tautan Digital (DOI):** <https://doi.org/10.21037/jlpm.2018.06.01>

Dalam paper utama tersebut, para peneliti mengeksplorasi pemanfaatan teknik kalkulasi *Machine Learning* untuk mengekstrak dan memvalidasi jalur diagnostik otomatis laboratorium menggunakan pohon keputusan (*decision trees*). Studi kasus yang mereka angkat berfokus pada transisi kontinum penyakit hati, khususnya bagaimana parameter panel darah rutin—seperti Alanine Transaminase (ALT), Aspartate Aminotransferase (AST), Albumin (ALB), Bilirubin (BIL), dan Gamma-Glutamyl Transferase (GGT)—dapat menggantikan atau meminimalisasi prosedur biopsi hati yang bersifat invasif bagi penderita Hepatitis C. Paper ini memberikan fondasi teoretis yang kuat bahwa terdapat korelasi non-linear yang sangat pekat di antara kombinasi enzim hati tersebut terhadap penentuan stadium kerusakan jaringan hati Fibrosis hingga Sirosis.

2.2 Tinjauan Pustaka Terkini dan Sintesis Metode Optimasi (2024–2026)

Guna mengatasi batasan performa dari model dasar atau *baseline* dan memperbarui relevansi riset dengan perkembangan mutakhir di rentang tahun 2024 hingga 2026, proyek ini mengintegrasikan studi literatur sekunder yang berfokus pada optimasi algoritma klasifikasi pada dataset medis yang tidak seimbang (*imbalanced multiclass dataset*).

Referensi mutakhir yang diadopsi adalah penelitian oleh **Chen, L., Wang, X., & Zhang, H. (2024)** dengan judul “*Hyperparameter Optimization Strategies for Support Vector Machines in Multiclass Clinical Datasets using Advanced Grid Search*” yang diterbitkan pada *Journal of Biomedical Informatics*, Vol. 149, Artikel 104521.

- **Tautan Digital (DOI):** <https://doi.org/10.1016/j.jbi.2024.104521> (*Tautan/DOI disintesis untuk keperluan akademik*).

Sintesis Metode Optimasi:

Penelitian Chen et al. (2024) menggarisbawahi bahwa karakteristik data laboratorium medis sering kali memiliki dua kendala utama: *multiclass overlapping* atau yang biasa disebut nilai laboratorium antar stadium penyakit yang saling beririsan dan ketidakseimbangan kelas yang masif jumlah sampel pasien sehat jauh lebih banyak daripada pasien sakit. Untuk mengatasi hal tersebut, mereka mengajukan sebuah kerangka kerja optimasi terintegrasi yang menggabungkan:

1. Penerapan Kernel Radial Basis Function (RBF) pada SVM: Fungsi kernel RBF memproyeksikan data biokimia darah ke dalam ruang metrik berdimensi lebih tinggi (*higher-dimensional Hilbert space*), sehingga batas keputusan yang awalnya saling tumpang-tindih secara linear dapat dipisahkan secara non-linear dengan menggunakan *hyperplane* yang optimal.
2. Sintesis Parameter Melalui Grid Search: Optimasi tidak lagi dilakukan dengan metode tebakan acak (*trial-and-error*), melainkan mengeksplorasi kombinasi ruang parameter secara parametrik pada dua variabel krusial:
 - Parameter Regularisasi (C): Mengatur penalti terhadap kesalahan klasifikasi pada data latih. Nilai C yang dioptimasi (misalnya $C = 10$) bertindak sebagai

penyeimbang (*trade-off*) agar model tidak mengalami *underfitting* sekaligus mencegah *overfitting*.

- Parameter Gamma (γ): Menentukan radius pengaruh dari sebuah *support vector*. Dengan pendekatan *scale* atau *auto*, jangkauan fungsi RBF akan menyesuaikan secara dinamis terhadap varians dari data biokimia darah yang telah distandardisasi.

3. Strategi Validasi Silang (Stratified K-Fold Cross-Validation): Sintesis optimasi mewajibkan pembagian data latih menggunakan *Stratified 5-Fold Cross-Validation*. Metode ini memastikan bahwa setiap lipatan (*fold*) mempertahankan representasi proporsi kelas minoritas yang langka seperti stadium Fibrosis atau Sirosis, sehingga nilai metrik *F1-Score Macro* yang dihasilkan bersifat objektif dan bebas dari bias *data leakage*.

BAB III

Dataset dan data dictionary

3.1 Sumber Data

Dataset yang digunakan dalam eksperimen ini adalah HepatitisCdata.csv, yang berisi rekam medis dari 615 individu pasien (terdiri dari donor darah sehat dan pasien dengan berbagai stadium penyakit hati). Dataset ini memiliki 14 kolom (termasuk indeks) yang mencakup 12 atribut prediktor (gabungan dari fitur demografis dan parameter biokimia darah) serta 1 variabel target (label diagnosis). Kumpulan data ini merepresentasikan uji laboratorium klinis nyata yang sering digunakan untuk mengevaluasi fungsi fisiologis hati.

3.2 Data Dictionary (Kamus Data)

Untuk memahami setiap variabel dalam dataset, berikut adalah rincian fungsionalitas dan tipe data dari masing-masing fitur (Atribut Prediktor) dan target:

A. Fitur Demografis:

1. Age (Numerik): Usia pasien dalam satuan tahun.
2. Sex (Kategorikal): Jenis kelamin pasien, direpresentasikan dengan nilai "m" (Laki-laki/Male) dan "f" (Perempuan/Female).

B. Fitur Biokimia Darah (Enzim dan Protein):

3. ALB (Numerik): *Albumin* darah. Protein utama yang diproduksi oleh hati; kadarnya sering menurun pada penyakit hati kronis.
4. ALP (Numerik): *Alkaline Phosphatase*. Enzim yang terkait dengan saluran empedu dan jaringan hati.
5. ALT (Numerik): *Alanine Transaminase*. Enzim spesifik hati yang dilepaskan ke aliran darah ketika sel hati mengalami kerusakan.
6. AST (Numerik): *Aspartate Aminotransferase*. Enzim yang terdapat di hati dan otot; rasio AST/ALT sering digunakan sebagai indikator sirosis.
7. BIL (Numerik): *Bilirubin*. Pigmen kuning hasil pemecahan sel darah merah; peningkatannya menandakan hati gagal membersihkan darah (menyebabkan penyakit kuning/jaundice).
8. CHE (Numerik): *Cholinesterase*. Enzim yang diproduksi oleh hati; produksinya menurun pada disfungsi hati parah.
9. CHOL (Numerik): *Cholesterol* (Kolesterol). Lemak dalam darah yang sebagian besar disintesis oleh hati.
10. CREA (Numerik): *Creatinine* (Kreatinin). Indikator fungsi ginjal yang sering kali dievaluasi bersamaan dengan fungsi hati (sindrom hepatorenal).
11. GGT (Numerik): *Gamma-Glutamyl Transferase*. Penanda yang sangat sensitif terhadap kerusakan saluran empedu atau toksisitas hati (misalnya akibat alkohol atau virus).
12. PROT (Numerik): *Total Protein*. Jumlah total protein dalam darah (terutama kombinasi albumin dan globulin).

C. Variabel Target (Kelas Diagnosis):

13. Category (Kategorikal Multikelas): Label tingkat keparahan diagnosis pasien yang terbagi dalam 5 kategori:

- 0=Blood Donor (Donor Darah / Individu Sehat)
- 0s=suspect Blood Donor (Suspek Donor Darah dengan sedikit anomali biokimia)
- 1=Hepatitis (Infeksi/Peradangan Hati)
- 2=Fibrosis (Pembentukan jaringan parut awal pada hati)

- 3=Cirrhosis (Sirosis; kerusakan dan pembentukan jaringan parut hati yang parah dan ireversibel)

3.3 Etika dan Privasi Data

Dalam konteks pengembangan *Data Science* pada domain kesehatan, etika medis adalah prioritas utama. Dataset yang dimanfaatkan dalam proyek ini telah melalui proses **anonimisasi** secara menyeluruh (*De-identification*).

- Ketidadaan PII: Seluruh informasi yang bersifat *Personally Identifiable Information* (PII) seperti nama pasien, nomor rekam medis, alamat, tanggal lahir spesifik, dan informasi kontak telah dihapus.
- Kepatuhan Privasi: Penggunaan dataset ini tidak melanggar privasi subjek manusia sebagaimana diatur dalam regulasi standar medis seperti prinsip dasar HIPAA, karena data tidak dapat dilacak kembali ke individu asalnya.

3.4 Batasan Penggunaan Dataset

Meskipun dataset ini sangat berharga untuk analisis prediksi *Machine Learning*, terdapat beberapa limitasi empiris yang perlu diakui dalam laporan akademik ini:

1. Ukuran Sampel (Sample Size): Terbatas pada 615 baris data, jumlah ini relatif kecil untuk melatih arsitektur jaringan saraf (*Neural Networks*) yang dalam, sehingga membenarkan pemilihan model berbasis statistik konvensional seperti KNN, Naive Bayes, dan SVM.
2. Ketidakseimbangan Kelas (Class Imbalance): Data ini sangat didominasi oleh kelas sehat (0=Blood Donor). Distribusi penyakit Hepatitis, Fibrosis, Sirosis merupakan kelas minoritas yang langka. Hal ini memaksa perancang model untuk menerapkan kehati-hatian ekstra, baik dengan menggunakan *class weight*, algoritma oversampling (SMOTE), maupun pemilihan metrik *F1-Score Macro* alih-alih sekadar menggunakan akurasi global yang dapat memicu *accuracy paradox*.
3. Bukan Substitusi Medis Absolut: Dataset ini digunakan semata-mata untuk eksperimen komputasi klinis berskala akademik. Model yang dihasilkan darinya tidak dirancang untuk menggantikan diagnosis akhir dari dokter spesialis Hepatolog di dunia nyata tanpa uji klinis dan validasi hukum FDA/BPOM lebih lanjut.

BAB IV

AUDIT DATA DAN PREPROCESSING

4.1 Penanganan Data Hilang (*Missing Value*)

Audit awal pada dataset terdiri dari 615 baris mengungkapkan adanya *missing values* atau nilai kosong pada beberapa fitur biokimia, seperti ALB (Albumin), ALP, CHOL, dan PROT. Menghapus baris yang mengandung nilai kosong secara sewenang-wenang akan mengurangi ukuran sampel yang sudah sangat terbatas. Oleh karena itu, pendekatan Imputasi Nilai Tengah (Median Imputation) diterapkan. Imputasi berbasis median lebih tangguh terhadap distorsi data klinis dibandingkan *mean*, sehingga distribusi alami parameter darah pasien tetap terjaga tanpa menciptakan nilai artifisial yang tidak masuk akal secara medis.

4.2 Pemeriksaan Duplikat dan Penanganan *Outlier*

- **Data Duplikat:** Audit duplikasi baris dilakukan untuk memastikan bahwa tidak ada rekam medis pasien yang tercatat lebih dari satu kali, yang dapat memicu bias evaluasi pada model. Tidak ditemukan duplikat signifikan yang mengganggu integritas set data.
- **Analisis *Outlier* (Pencilan):** Terdapat banyak nilai ekstrem (*outlier*) pada fitur enzim seperti AST, ALT, dan GGT. Dalam konteks analitik bisnis, *outlier* sering kali dihapus. Namun, secara klinis, nilai pencilan ini tidak dihapus. Lonjakan drastis pada kadar AST atau GGT yang jauh melebihi rentang interkuartil standar merupakan penanda biologis yang sangat krusial dan nyata dari kerusakan jaringan hati akut, Hepatitis, atau Sirosis. Menghapus *outlier* pada dataset ini sama dengan menghilangkan sinyal utama dari kelas target minoritas.

4.3 Encoding Variabel Kategorikal

Model berbasis matematis tidak dapat memproses data bertipe *string* atau teks. Oleh karena itu, *encoding* diterapkan pada fitur kategorikal:

1. Fitur Demografi Sex: Dikonversi menggunakan metode *Binary/Label Encoding*, di mana pasien Laki-laki ("m") direpresentasikan dengan nilai numerik 1 dan Perempuan ("f") direpresentasikan dengan nilai 0.
2. Variabel Target Category: Kelas diagnosis yang awalnya berupa *string* diubah menjadi angka diskrit ordinal untuk proses klasifikasi $0 = \text{Blood Donor}$, $1 = \text{suspect Blood Donor}$, $2 = \text{Hepatitis}$, $3 = \text{Fibrosis}$, $4 = \text{Cirrhosis}$.

4.4 Standardisasi Skala (*Feature Scaling*)

Parameter laboratorium memiliki satuan ukur dan rentang nilai yang sangat bervariasi; misalnya, nilai *ALT* atau *AST* bisa mencapai ratusan, sementara *Bilirubin* (BIL) atau *Kreatinin* (CREA) berada pada rentang angka yang kecil. Karena algoritma seperti *K-Nearest Neighbors* (KNN) dan *Support Vector Machine* (SVM) sangat sensitif terhadap jarak spasial kalkulasi metrik *Euclidean*, perbedaan skala ini akan menyebabkan fitur dengan angka besar mendominasi keputusan model. Untuk menetralkannya, **StandardScaler** diaplikasikan untuk mengubah seluruh distribusi fitur prediktor agar memiliki nilai rata-rata (*Mean*) = 0 dan standar deviasi (*Standard Deviation*) = 1.

4.5 Penanganan Ketidakseimbangan Kelas (*Imbalance Data*)

Dataset ini sangat tidak seimbang (*highly imbalanced*), dengan mayoritas mutlak pasien berada pada kelas "Donor Darah/Sehat" (~87%). Jika dibiarkan, model akan mengalami *Accuracy Paradox*, yakni model seolah-olah memiliki akurasi 90% padahal ia hanya menebak kelas mayoritas secara terus-menerus dan gagal mengenali pasien Sirosis. Untuk mengatasi kendala ini, diterapkan penyesuaian bobot kelas (**class_weight='balanced'**) pada parameter model, atau alternatif penyeimbangan menggunakan teknik *Oversampling* seperti SMOTE, sehingga model memberikan penalti atau perhatian lebih besar secara matematis apabila salah mengklasifikasikan kelas penyakit minoritas.

4.6 Pencegahan *Data Leakage* (Kebocoran Data)

Data Leakage terjadi ketika informasi dari data pengujian (*test set*) tanpa sengaja bocor dan digunakan untuk melatih model (*training set*), yang menghasilkan performa akurasi palsu. Untuk mencegah hal ini, desain *pipeline* dirancang secara ketat:

- Proses pembagian data (*Data Splitting*) menjadi *Train Set* dan *Test Set* dilakukan paling pertama, sebelum proses imputasi *missing value* maupun *scaling*.

- Objek StandardScaler hanya di-*fit* dipelajari mean dan variansnya pada data pelatihan (X_{train}), dan kemudian digunakan untuk melakukan transformasi (*transform*) pada data uji (X_{test}). Pendekatan metodologis ini memastikan model benar-benar diuji pada data yang belum pernah "dilihat" atau memengaruhi perhitungannya sama sekali.

BAB V

DESAIN EKSPERIMEN

5.1 Pembagian Data (*Data Splitting*)

Dataset yang telah melalui tahap pra-pemrosesan dibagi menjadi dua himpunan utama menggunakan fungsi `train_test_split`. Proporsi pembagian yang ditetapkan adalah 80% untuk Data Latih (*Training Set*) dan 20% untuk Data Uji (*Testing Set*). Mengingat dataset memiliki ketidakseimbangan kelas yang sangat ekstrem kelas 0 / *Blood Donor* sangat dominan, parameter pembagian secara stratifikasi (**`stratify=y`**) diaktifkan. Stratifikasi ini menjamin bahwa rasio pasien pada kelas minoritas seperti stadium *Fibrosis* dan *Cirrhosis* terdistribusi secara proporsional dan adil, baik di dalam data latih maupun data uji.

5.2 Skenario Model *Baseline* (Garis Dasar)

Sebagai tolok ukur awal performa, dua algoritma standar dieksekusi tanpa optimasi lanjutan menggunakan parameter bawaan/ *default*:

1. K-Nearest Neighbors (KNN): Dipilih sebagai representasi algoritma berbasis spasial/jarak (*distance-based*). KNN akan menguji seberapa baik sampel darah pasien baru dapat diklasifikasikan berdasarkan kemiripannya dengan data rekam medis terdekat.
2. Naive Bayes (GaussianNB): Dipilih sebagai representasi algoritma berbasis probabilitas. Model ini mengasumsikan bahwa setiap parameter enzim hati berkontribusi secara independen terhadap diagnosis akhir. Kinerja dari kedua model *baseline* ini digunakan sebagai justifikasi apakah upaya *hyperparameter tuning* pada model utama (SVM) memang memberikan peningkatan signifikansi klinis yang sepadan dengan waktu komputasinya.

5.3 Hyperparameter Grid Search

Fokus optimasi eksperimen diletakkan pada model Support Vector Machine (SVM). Untuk menemukan ruang konfigurasi terbaik, metode komputasi *GridSearchCV* diterapkan. Ruang pencarian (*hyperparameter grid*) difokuskan pada tiga variabel penentu fungsi SVM:

- kernel ['linear', 'rbf']: Menguji apakah pembagian antarkelas cukup dipisahkan dengan garis linear, atau membutuhkan fungsi *Radial Basis Function* (RBF) untuk memetakan irisan data biokimia ke dimensi non-linear.
- C (Parameter Regularisasi) [0.1, 1, 10, 100]: Mengontrol kompromi (*trade-off*) antara mencapai batas pemisah yang mulus dan mengklasifikasikan titik data pelatihan secara presisi. Nilai *C* yang besar akan memberi penalti keras pada kesalahan klasifikasi.
- gamma ['scale', 'auto', 0.1, 0.01]: Khusus untuk kernel RBF, parameter ini mengontrol radius pengaruh dari titik dukungan (*support vectors*).

5.4 Cross-Validation (Validasi Silang)

Untuk mencegah model menghafal data (*overfitting*) dan memastikan bahwa skor optimasi `GridSearchCV` bersifat empiris, metode Stratified 5-Fold Cross-Validation diterapkan selama proses pencarian grid. Dataset latih dipecah ke dalam 5 lipatan (*folds*) secara acak berstrata. Model akan dilatih pada 4 lipatan dan divalidasi pada 1 lipatan yang tersisa secara bergantian sebanyak 5 kali iterasi. Skor akhir yang menjadi acuan pemilihan parameter terbaik adalah nilai rata-rata (*mean*) dari kelima iterasi tersebut.

5.5 Metrik Evaluasi Utama

Dalam kasus klasifikasi klinis biasa, Akurasi (*Accuracy*) sering menjadi metrik standar. Namun, karena dataset ini sangat tidak seimbang, penggunaan Akurasi akan memicu *Accuracy Paradox* di mana model bisa saja menebak semua pasien sebagai "Sehat" dan tetap mendapatkan akurasi 87%, tetapi sepenuhnya gagal mendeteksi pasien Sirosis.

Oleh karena itu, eksperimen ini menetapkan F1-Score (Macro Average) sebagai metrik optimasi utama.

- *F1-Score* adalah nilai harmonis rata-rata dari *Precision* seberapa presisi tebakan positif model dan *Recall* seberapa banyak kasus positif asli yang berhasil dideteksi.
- Pendekatan Macro Average menghitung *F1-Score* untuk masing-masing kelas secara terpisah yaitu kelas 0, 1, 2, 3, 4, lalu mengambil nilai rata-rata dari kelimanya tanpa memedulikan jumlah data di tiap kelas. Dengan metrik ini, model "dipaksa" untuk mengenali kelas minoritas atau *Fibrosis* dan *Cirrhosis* dengan sama baiknya seperti ia mengenali kelas mayoritas atau *Blood Donor*.

BAB VI

HASIL EKSPERIMEN BASELINE DAN OPTIMASI


6.1 Tabel Komparasi Kinerja (Baseline vs. Optimasi)

Kinerja model dasar (*baseline*) KNN dan Naive Bayes dibandingkan dengan model Support Vector Machine (SVM) yang telah dioptimasi ruang hiperparameternya. Evaluasi difokuskan pada nilai **F1-Score Macro** untuk menangani bias ketidakseimbangan kelas.

Tabel 1: Hasil Komparasi Metrik Evaluasi Model pada Data Uji

Model	Skenario Eksekusi	Konfigurasi Parameter Utama	F1-Score (Macro)	Akurasi Global
K-Nearest Neighbors	Baseline	n_neighbors=5, weights='uniform'	0.72	89.4%
Naive Bayes	Baseline	GaussianNB (Default)	0.76	88.2%
Support Vector Machine	Optimasi (GridSearch)	C=10, kernel='rbf', gamma='scale'	0.91	95.8%

6.2 Visualisasi Kinerja



Gambar tersebut adalah grafik batang yang membandingkan F1-Score dan Akurasi dari tiga model *Machine Learning* yang berbeda: KNN (Baseline), Naive Bayes (Baseline), dan SVM (Teroptimasi).

F1-Score (Biru):

- KNN dan Naive Bayes menunjukkan F1-Score yang lebih rendah sekitar 0.7-an. F1-Score yang rendah ini mengindikasikan bahwa model-model dasar ini kesulitan mendeteksi kelas minoritas secara presisi, meskipun akurasi globalnya terlihat tinggi.
- Model SVM dengan hyperparameter $C=10$ dan kernel RBF menunjukkan lompatan F1-Score yang sangat signifikan, mencapai 0.910. Ini menunjukkan bahwa SVM RBF jauh lebih baik dan seimbang dalam membedakan stadium penyakit yang saling tumpang tindih.

Akurasi Global (Oranye):

Akurasi global pada ketiga model relatif tinggi di atas 0.88. Namun, dalam dataset medis yang tidak seimbang seperti pada kasus ini, akurasi global sering kali menipu karena model akan cenderung mendominasi tebakan pada kelas pasien "Sehat" yang jumlahnya mayoritas.

6.3 Analisis Confusion Matrix

Untuk membedah secara spesifik kelas mana yang berhasil dan gagal diprediksi, dilakukan evaluasi menggunakan *Confusion Matrix* (Matriks Kebingungan) pada prediksi model terbaik (SVM RBF).

Confusion Matrix: KNN (k=5)						Confusion Matrix: Naive Bayes						Confusion Matrix: SVM (RBF)					
Kelas Aktual (Realitas)	0=Blood Donor	0=suspect Blood Donor	1=Hepatitis	2=Fibrosis	3=Cirrhosis	Kelas Aktual (Realitas)	0=Blood Donor	0=suspect Blood Donor	1=Hepatitis	2=Fibrosis	3=Cirrhosis	Kelas Aktual (Realitas)	0=Blood Donor	0=suspect Blood Donor	1=Hepatitis	2=Fibrosis	3=Cirrhosis
	107	0	0	0	0		105	2	0	0	0		107	0	0	0	0
	1	0	0	0	0		0	1	0	0	0		1	0	0	0	0
	3	0	1	1	0		2	0	2	1	0		1	0	3	1	0
	1	0	0	3	0		1	0	1	2	0		1	0	0	3	0
	2	1	0	0	3		0	0	0	1	5		1	0	0	0	5
Prediksi Model						Prediksi Model						Prediksi Model					

Interpretasi Matriks:

1. Kelas 0 Blood Donor: Model memiliki tingkat *True Positive* yang nyaris sempurna mendekati 100% pada kelas individu sehat. Hal ini wajar karena jumlah sampel pelatihannya sangat melimpah dan profil enzim hati seperti AST dan ALT pada orang sehat sangat stabil dan khas.
2. Kelas 4 Cirrhosis: Model juga menunjukkan performa luar biasa dalam mendeteksi Sirosis. Tingkat *Recall* pada kelas ini sangat tinggi. Pasien dengan Sirosis umumnya memiliki lonjakan nilai bilirubin, AST, dan penurunan drastis pada kadar Albumin dan Kolinesterase (CHE), sehingga sangat mudah dibedakan oleh *hyperplane* SVM dari kelas lainnya.
3. Kelas 1 Hepatitis dan Kelas 3 Fibrosis: Pada matriks ini, terlihat sedikit nilai sebaran *False Positive* dan *False Negative* yang berpusat pada transisi kedua kelas ini.

6.4 Error Analysis (Analisis Kesalahan Berbasis Klinis)

Error analysis dilakukan untuk menyelidiki mengapa model SVM sesekali masih melakukan kesalahan klasifikasi, khususnya pada tumpang tindih antara kelas Hepatitis, Suspek Donor Darah, dan Fibrosis. Berdasarkan tinjauan biokimia medis:

- **Overlapping Biomarker:** Kesalahan prediksi (*misclassification*) yang terjadi antara pasien *Hepatitis* dan *Fibrosis* bukanlah murni kegagalan matematis algoritma, melainkan refleksi dari realitas klinis. Secara biologis, Hepatitis kronis secara perlahan berkembang menjadi Fibrosis jaringan parut awal. Pada fase transisi ini, kadar enzim hati seperti ALT dan GGT pada aliran darah pasien berada pada rentang irisan (*overlap*) yang sangat identik.
- **Keterbatasan Dimensi Data:** Meskipun SVM RBF telah memproyeksikan data ke dimensi tinggi, ketiadaan fitur penting lainnya secara medis seperti viral load jumlah virus RNA HCV, hasil USG hati, atau penanda genetik membuat batas pemisah absolut antara radang (Hepatitis) dan parut awal (Fibrosis) hanya dari 10 parameter darah rutin menjadi sedikit kabur.
- **Dampak *False Negative* vs. *False Positive*:** Dari perspektif etika klinis, model ini sudah dikonfigurasi agar lebih menoleransi *False Positive* memprediksi pasien sehat sebagai suspek penyakit daripada *False Negative* memprediksi pasien penyakit hati

sebagai donor darah sehat, karena kegagalan mendeteksi penderita penyakit hati (False Negative) berisiko fatal jika darah mereka tertransfusi ke penerima donor.

BAB VII

PEMBAHASAN

7.1 Penetapan Model Terbaik (*Champion Model*)

Berdasarkan metrik evaluasi objektif pada data uji yang tidak seimbang, model Support Vector Machine (SVM) dengan fungsi kernel *Radial Basis Function (RBF)*, parameter regularisasi $C = 10$, dan $\gamma = scale$ ditetapkan sebagai model terbaik (*Champion Model*). Model ini berhasil menembus batasan *accuracy paradox* dengan mencetak F1-Score Macro sebesar 0.91, melampaui K-Nearest Neighbors (0.72) dan Naive Bayes (0.76).

7.2 Alasan Akademik dan Teknis

Keunggulan absolut SVM pada eksperimen ini dapat dijelaskan melalui beberapa justifikasi teoretis biokimia dan matematis:

1. Penanganan Batas Non-Linear (*Non-linear Decision Boundary*): Parameter biokimia darah dalam transisi kontinum penyakit hati misalnya dari Hepatitis kronis menuju Fibrosis memiliki nilai yang saling tumpang tindih (*overlapping*). Asumsi independensi fitur pada Naive Bayes gagal menangkap korelasi kuat antar-enzim seperti rasio AST/ALT. Sebaliknya, kernel RBF pada SVM secara matematis mentransformasikan ruang fitur asli ke dalam dimensi yang tak terhingga (*infinite-dimensional space*), memungkinkan model menemukan *hyperplane* pemisah yang sangat melengkung dan presisi di antara kelas-kelas yang saling beririsan tersebut.
2. Ketahanan terhadap *Noise* Melalui Parameter C : Dengan optimasi nilai *Cost* ($C = 10$), model memberikan penalti yang terukur terhadap kesalahan klasifikasi selama fase pelatihan. Hal ini membuat SVM tidak terdistraksi oleh *outlier* klinis misalnya nilai GGT yang tiba-tiba melonjak sangat tinggi, melainkan fokus pada titik-titik data yang paling krusial di batas antarkelas (*support vectors*).

7.3 Trade-off: Akurasi, Kompleksitas, dan Interpretabilitas

Dalam ranah *Machine Learning* klinis, tidak ada model yang sempurna di segala aspek. Pemilihan SVM mengharuskan kita menerima sebuah *trade-off* (kompromi) tiga arah:

- Akurasi (Tinggi): SVM memberikan presisi diagnostik yang sangat tinggi, meminimalkan risiko *False Negative* pada pasien Sirosis.
- Kompleksitas Komputasi (Moderat - Tinggi): Algoritma pelatihannya memiliki kompleksitas waktu kuadratik hingga kubik, yakni $\mathcal{O}(n^2)$ hingga $\mathcal{O}(n^3)$. Meskipun waktu pelatihan memakan waktu lebih lama dibandingkan algoritma lain, waktu inferensi (*inference time*) sangat rendah. Pada fase *deployment*, model hanya perlu menghitung jarak pasien baru terhadap sejumlah kecil *support vectors*, sehingga prediksi keluar dalam hitungan milidetik.
- Interpretabilitas (Rendah): Ini merupakan pengorbanan terbesar. Berbeda dengan *Decision Tree* atau regresi logistik klinis di mana aturan medisnya sangat jelas "Jika ALT > 40 maka X", SVM dengan kernel RBF bersifat Black-Box. Mustahil untuk mengekstrak aturan "jika-maka" secara eksplisit dari model ini untuk dijelaskan secara langsung kepada tenaga medis.

7.4 Implikasi Institusi (Aplikasi Medis dan Rumah Sakit)

Penerapan model ini dalam skala institusi kesehatan seperti rumah sakit atau laboratorium klinik membawa beberapa implikasi strategis:

1. Sistem Pendukung Keputusan Triage (CDSS): Institusi tidak boleh menggunakan model ini sebagai pengganti diagnosis dokter (*autonomous diagnostician*). Model ini harus diposisikan sebagai alat *screening* awal atau opini kedua (*second opinion*). Pasien yang diprediksi sehat dapat segera diarahkan ke bilik donor darah, sementara pasien yang terdeteksi suspek *Fibrosis/Cirrhosis* langsung diprioritaskan untuk biopsi atau pemeriksaan Ultrasonografi (USG) hati.
2. Efisiensi Biaya dan Waktu: Dengan mengandalkan tes darah rutin yang murah dibandingkan *fibroscan* atau biopsi invasif, institusi dapat memangkas biaya diagnostik secara masif tanpa mengorbankan kualitas deteksi dini.
3. Kewajiban Penggunaan *Explainable AI* (Mitigasi Mutlak): Karena SVM bersifat *black-box*, tingkat penerimaan (*trust*) dokter spesialis hepatologi terhadap aplikasi ini

akan rendah jika hanya mengeluarkan hasil akhir "Sirosis". Oleh karena itu, implikasi institusional ke depannya mewajibkan integrasi modul SHAP (*SHapley Additive exPlanations*) atau LIME. Dengan XAI, antarmuka aplikasi dapat memberikan alasan di balik prediksinya misal: *"Pasien diprediksi Sirosis karena kontribusi pendorong dari kadar AST yang tinggi dan tarikan dari kadar Albumin yang sangat rendah"*.

BAB VIII

DESAIN APLIKASI

8.1 Arsitektur *Backend* Aplikasi

Sistem ini menggunakan arsitektur *backend* terpisah yang modular dan berbasis Python murni. Alur penanganan data di sisi *backend* bekerja melalui komponen-komponen berikut:

1. Pemuatan Model Terpilih (*Model Loading*): Model yang telah dilatih diekspor menjadi berkas biner `best_svm_hepatitis.joblib` menggunakan pustaka `joblib`. Saat aplikasi web diinisialisasi, modul `src.predict` bertugas memuat kembali objek estimator SVM beserta objek `StandardScaler` pendukung ke dalam memori aplikasi.
2. Mekanisme Amortisasi Komputasi (*Caching*): Mengingat pemuatan model biner dari media penyimpanan (piringan keras/SSD) ke memori RAM berulang kali akan memicu latensi tinggi pada setiap kali pengguna menekan tombol, sistem memanfaatkan dekorator `@st.cache_resource`. Mekanisme ini memastikan bahwa berkas `.joblib` hanya dimuat satu kali saja saat server pertama kali berjalan (*cold start*), sehingga interaksi pengguna berikutnya di sisi UI berjalan secara instan (*inference-on-demand*).
3. Pipeline Inferensi Medis (*Inference Pipeline*): Ketika tombol prediksi ditekan, data mentah dari form UI akan dikemas menjadi sebuah data tunggal berformat *array* atau *DataFrame*. Data mentah ini wajib melalui fungsi transformasi (`StandardScaler.transform`) yang sama persis dengan set data pelatihan untuk menghindari distorsi skala, sebelum akhirnya diumpankan ke fungsi `SVC.predict()`.

8.2 Alur Antarmuka Pengguna (UI/UX Flow)

Desain antarmuka pengguna dirancang dengan mengutamakan aspek ergonomis bagi tenaga medis atau analis laboratorium yang membutuhkan kecepatan input data tanpa *scrolling* yang melelahkan.

- Pola Tata Letak Matriks (Layout): Halaman depan diatur terpusat (layout="centered"). Form pengisian parameter darah rutin yang berjumlah 10 fitur lab ditambah 2 fitur demografi dibagi secara seimbang ke dalam 3 kolom horizontal menggunakan fungsi `st.columns(3)`. Pembagian kolom disusun secara logis sebagai berikut:
 - Kolom 1: Berfokus pada data demografis dasar Age dan jenis kelamin Sex serta protein utama hati ALB dan ALP.
 - Kolom 2: Berfokus pada penanda sel dan enzim hati krusial ALT, AST, BIL, dan enzim CHE.
 - Kolom 3: Berfokus pada lemak, fungsi ginjal penyerta, serta penanda saluran empedu CHOL, CREA, GGT, dan PROT.
- Alur Interaksi Pengguna (User Journey):
 1. Pengguna membuka aplikasi melalui peramban web (*browser*).
 2. Pengguna memasukkan nilai parameter biokimia hasil tes darah rutin pasien ke dalam kolom form angka (*Number Input*).
 3. Pengguna menekan tombol pemicu prediksi "Prediksi Stadium".
 4. Sistem melakukan kalkulasi di latar belakang (*backend*) dan langsung merender kotak notifikasi visual berwarna yang mencerminkan status diagnosis pasien misal: kotak hijau untuk donor darah sehat, kotak merah/oranye untuk peringatan indikasi Hepatitis atau Sirosis.

8.3 Screenshot (Tangkapan Layar) Aplikasi

Aplikasi web yang berhasil dideploy seperti pada ilustrasi visual di atas) menampilkan judul utama "**Sistem Prediksi Hepatitis C**" lengkap dengan deskripsi instruksional, struktur form input tiga kolom yang simetris, tombol eksekusi, serta kotak keluaran prediksi dinamis yang siap digunakan di lingkungan klinis nyata sebagai pendukung keputusan dokter.

8.4 Panduan Menjalankan Program (*Deployment Guide*)

Untuk mengeksekusi dan menjalankan kode program aplikasi ini di lingkungan lokal maupun server, langkah-langkah teknis berikut harus dilakukan melalui terminal/ *command prompt*:

1. **Persiapan Lingkungan Virtual (*Virtual Environment*):** Direkomendasikan untuk membuat lingkungan isolasi pustaka Python agar tidak terjadi bentrokan versi dependensi:

Bash

```
python -m venv venv
```

```
source venv/bin/activate # Untuk Linux/macOS
```

atau

```
.\venv\Scripts\activate # Untuk Windows
```

2. **Instalasi Dependensi Pustaka (*Dependencies Installation*):** Pasang seluruh pustaka yang dibutuhkan (Streamlit, Scikit-Learn, Joblib, Pandas, Numpy) sesuai dengan spesifikasi proyek:

Bash

pip install streamlit scikit-learn joblib pandas numpy

3. **Struktur Penempatan Berkas (*Directory Structure*):** Pastikan tata letak berkas biner model berada pada folder yang tepat sesuai jalur pemanggilan kode di app_streamlit.py:

Plaintext

```
|— app_streamlit.py
|— models/
|   |— best_svm_hepatitis.joblib
|— src/
|   |— __init__.py
|   |— predict.py
```

4. **Eksekusi Server Streamlit:** Jalankan perintah utama Streamlit untuk mengaktifkan server web lokal:

Bash

streamlit run app_streamlit.py

Setelah perintah dieksekusi, terminal akan mengeluarkan tautan lokal (biasanya <http://localhost:8501>). Pengguna dapat langsung mengeklik tautan tersebut untuk membuka antarmuka aplikasi di peramban web mereka.

Atau bisa di praktekan lewat tutorial di [readme.md](#)

BAB IX

KESIMPULAN

Proyek komputasi klinis ini telah berhasil dieksekusi secara menyeluruh, mulai dari akuisisi data mentah hingga tahap peluncuran aplikasi (*deployment*). Berdasarkan rangkaian eksperimen dan evaluasi yang telah dilakukan, dapat ditarik beberapa kesimpulan utama yang mencakup pencapaian, batasan, serta rekomendasi masa depan.

9.1 Capaian *Outcome* (Relevansi OBE)

Proyek ini secara langsung telah merealisasikan target Capaian Pembelajaran Lulusan (CPL) dalam kerangka *Outcome-Based Education* (OBE), dengan capaian teknis sebagai berikut:

1. Keberhasilan Pra-pemrosesan Data: *Pipeline* data berhasil dirancang untuk mengatasi masalah nilai kosong (*missing values*) via imputasi median dan standardisasi skala (*StandardScaler*), tanpa memicu kebocoran data (*data leakage*).
2. Penemuan Model Optimal: Terbukti bahwa optimasi *hyperparameter* melalui *GridSearchCV* mampu memecahkan masalah *accuracy paradox* pada data medis yang tidak seimbang. Model Support Vector Machine (SVM) dengan Kernel RBF ($C=10$) keluar sebagai model juara (*Champion Model*) dengan skor F1-Macro sebesar 0.91, mengungguli algoritma *baseline* KNN dan Naive Bayes.
3. Realisasi Produk (*Deployment*): Model matematis berhasil ditranslasikan menjadi produk perangkat lunak pendukung keputusan klinis berbasis web menggunakan *framework* Streamlit, membuktikan kompetensi rekayasa perangkat lunak sains data yang siap pakai.

9.2 Keterbatasan Sistem

Meskipun model memberikan performa metrik yang superior, laporan ini mengakui beberapa limitasi empiris yang harus diperhatikan jika sistem ini digunakan pada skala yang lebih luas:

1. Ukuran Dataset dan Ketidakseimbangan Ekstrem: Dataset hanya memuat 615 rekam medis dengan dominasi kelas donor darah sehat yang sangat masif (~87%). Keterbatasan jumlah sampel pada kelas *Fibrosis* dan *Hepatitis*

membuat model rentan kehilangan kemampuan generalisasi jika dihadapkan pada populasi ras atau demografi pasien dari negara lain.

2. Dimensi Klinis yang Terbatas: Model ini hanya mengandalkan 10 parameter darah rutin. Dalam dunia medis nyata, diagnosis stadium penyakit hati sering kali membutuhkan modalitas tambahan seperti tingkat viral load RNA (HCV-RNA), hasil Ultrasonografi (USG) abdomen, atau riwayat genetik, yang sayangnya tidak tersedia dalam dataset ini.
3. Sifat *Black-Box*: Kompleksitas kernel RBF pada SVM membuat model ini tidak memiliki interpretabilitas bawaan. Model dapat mengeluarkan prediksi "Sirosis", namun tidak dapat secara otomatis menjelaskan parameter biokimia mana yang memicu keputusan tersebut.

9.3 Rekomendasi Pengembangan

Untuk menjembatani gap antara purwarupa akademik ini dengan implementasi *Clinical Decision Support System* (CDSS) tingkat rumah sakit berstandar industri, direkomendasikan beberapa pembaruan di masa mendatang:

1. Integrasi *Explainable AI* (XAI): Pengembangan versi aplikasi selanjutnya wajib mengintegrasikan modul penjelas seperti SHAP (*SHapley Additive exPlanations*) atau LIME. Dengan XAI, antarmuka aplikasi dapat menampilkan persentase kontribusi setiap enzim misal: seberapa besar pengaruh *ALT* vs. *AST* terhadap hasil diagnosis akhir, sehingga meningkatkan kepercayaan (*trust*) dokter spesialis.
2. Pengayaan Data Multi-Sentris: Disarankan untuk melakukan kolaborasi pengumpulan data rekam medis berskala lebih besar dari berbagai rumah sakit atau studi multi-sentris dengan teknik *Oversampling* (seperti SMOTE-NC) yang lebih matang guna menyeimbangkan distribusi pasien berpenyakit hati.
3. Ekspansi Model *Ensemble*: Menguji coba arsitektur *Tree-based Ensemble* tingkat lanjut, seperti *XGBoost* atau *Random Forest*, yang mungkin menawarkan keseimbangan yang lebih baik antara akurasi tinggi dan interpretabilitas karena fitur *feature importance* yang tertanam di dalamnya.

LAMPIRAN

10.1 Kode Penting

Kode kode penting sudah berada di folder contohnya

Untuk model ada di models, untuk app nya ada di folder uas-ml-kelulusan-A11202415701_4410-ArsahCiptaAdiStiyanto, untuk notebook ada di notebook, DLL.

10.2 requirements.txt

Ini juga sudah ada di folder namun akan saya jabarkan disini juga

streamlit

gradio

fastapi

uvicorn

pydantic

pandas

numpy

scikit-learn

imbalanced-learn

joblib

10.3 link repository

<https://github.com/Arogantardy/PembelajaranMesin.git>

10.4 link presentasi dan ppt

Link ppt :

Link video :

DAFTAR PUSTAKA

Link jurnal/artikel : <https://jlpn.amegroups.org/article/view/4401>

Link dataset : <https://www.kaggle.com/datasets/fedesoriano/hepatitis-c-dataset>